# DPCrawler RAG 跨服检索引擎 API 接口文档

DPCrawler 底层检索引擎已经完成**核心重构**。目前实现了“前端绝美高保真渲染”与“后端毫秒级脱水索引”的双轨制完美解耦。 为了支持**跨服务器、分布式部署**（例如大语言模型服务器在 A 机器，爬虫和知识库在 B 机器），本接口采用标准的 **HTTP RESTful API + 内置静态资源 CDN** 架构，向外部提供高精度、低噪音的增强检索（RAG）语料块及原装附件访问能力。

---

## 1. 站点查询接口：`GET /api/v1/search`（废弃，已迁移为独立端点）

> **注意**：请使用 `GET /api/v1/sites` 获取全量知识库目录（支持无依赖零配置的便携版部署发现）。

### 1.1 获取站点列表: `GET /api/v1/sites`

查询当前服务器（或默认 portable `output` 根目录）下已挂载的所有独立爬虫站点数据集名称。第三方 UI 可借助该接口生成下拉菜单。

- **返回格式**: `["SiteA", "SiteB", "Dp_Gov"]`

---

## 2. 核心检索接口：`POST /api/v1/search`

作为分布式知识库检索入口，允许外部 Agent 跨网调用。

### 2.1 输入参数 (Request Payload)

Content-Type: `application/json`

| 字段名 | 类型 | 必填 | 描述 |
|---|---|---|---|
| `site_name` | `String` | 是 | 具体需要检索的站点工程名（用于限定知识库范围，避免串站）。 |
| `output_dir` | `String` | 否 | 后台数据的根存储路径，不传时默认在当前工作目录的 `output` 文件夹中寻找。当部署到远程生产环境时可传递指定盘符。 |
| `query` | `String` | 是 | 用户的自然语言查询内容，或大段的长提示词（系统具有自动泛用分词和降噪能力）。 |
| `top_k` | `usize` | 是 | 期望返回的最高权重文档碎片的数量上限（如 `5`）。 |
| `threshold` | `f64` | 否 | 相似度或密度的最低放行阈值（默认为 `0.0` 即不过滤），用于屏蔽低质量匹配。 |

### 2.2 输出结果 (Response Array)

返回一个包含多个 `SearchResult` 对象的 JSON 数组。由于跨服务器调用无法读取宿主机的物理盘，系统不再返回无意义的绝对路径，而是直接给出来自内置 CDN 的 **文件下载与访问 URL**。

```
[
  {
    "filename": "docs/2026年报名简章.md", // 相对于站点根目录的文件相对路径
    "title": "2026年同等学力人员申请硕士学位报考指南",
    "score": 45,
    "snippet": "2026 年同等学力人员申请硕士学位外国语水平...报名流程见附件。",
    "url": "https://tdxl.neea.edu.cn/notice/1", // 互联网上的原始出处
    "start_line": 24,
    "end_line": 28,
    "matched_block": "（二）考试报名\n符合报考资格的考生须于 3 月 16 日...", //
【核心投喂物】被动态滑窗提取出的连续上下文切片，直接作为 RAG 知识送入远程 LLM。
    "local_path": "/absolute/path/to/output/...md", // 物理机上的原始绝对位置

    // 【跨服核心】通过 DPCrawler 内置静态服务器（或 Nginx）暴露的相对路径链接
    "md_download_url": "/files/SiteA/docs/2026年报名简章.md?output_dir=...",
// LLM 用来即时拉取万字全文的接口
    "html_view_url": "/files/SiteA/html_views/2026年报名简章.html?
output_dir=...&highlight=...", // 前端 UI 直接塞入 Iframe 画布的高保真远端视觉链
接（底层支持包含标点空格的全自然语句智能切割）
    "html_block_view_url": "/files/SiteA/html_views/2026年报名简章.html?
output_dir=...&highlight_block=..." // 锚定具体块片段的高亮链接
  }
]
```

---

## 3. 远端渲染高保真回显规范（DOM 跨服同步染色定位）

当第三方业务流（无论是在云端、微信小程序还是远程网页）接收到上述 JSON 后，可以直接借助自带的 CDN 取到 HTML 以供极美展示。

为了保留 API 测试特有的“黄屏聚焦”，跨服前端需使用**跨模态寻址对齐策略**：

1. **Iframe 挂载**：直接将响应体中的 `html_view_url` 赋给原生 `<iframe src="...">`，利用浏览器内置引擎无损下载并渲染含数十万绝对定位元素的 `pdf2htmlEX` 页面。
2. **锚点提取**：取出 JSON 中的 `matched_block` 或 `query` 词，底层引擎自动调用了 Chromium 原生的 `Intl.Segmenter` API 拦截处理大段人类语言指令，将其碎为高亮核心阵列；对区段高亮则自动剥离外部链接形式以剔除杂交影响。
3. **脱水双向滑窗对齐（TreeWalker Range）**： 等 iframe `onload` 加载完毕，在前端执行探测脚本。将 HTML `<body>` 拍扁为纯文本流，不再死板地寻找开头前20字（可能遭遇 Markdown 附带 `<title>` 表头失效的场景），而是改用 **双向滑窗碰撞算法** 跳过一切头图、无用导航与冗余表头，强行精确咬合目标文本的物理生存位置点！ 拉取 Web `Range` API，利用 `TreeWalker` 把框定范围内的所有远程物理节点强行包裹底色层，并实现屏幕至焦点的平稳全自动滚动 `scrollIntoView()`。

通过这种 **CDN 派发文件 + 客户端动态脱水渲染** 的跨服架构：

- **后端（Crawler）** 完全免去了跨网传输百兆 HTML 的巨大成本负担。
- **大模型（LLM）** 仅接受极简纯净的 `.md` 文本或 URL，节省海量 Token 钱。
- **人类用户** 依然能从远端获得拥有 100% 物理字体排版权威感的高定原装预览！